


Práctica APA - Salario Justo

8 de enero de 2026 - Q1 2526



Departamento de Ciencias de la Computación

Grado en Ingeniería Informática - UPC

Esteve Estop

Sambhav Mayani

Índice

8 de enero de 2026	1
Departamento de Ciencias de la Computación	1
Grado en Ingeniería Informática - UPC	1
Índice	2
1. Descripción del problema	3
1.1. Descripción del conjunto de datos	3
1.2. Descripción de las variables	3
2. Preprocesamiento de datos	4
2.1. Limpieza de los datos y selección de características	4
2.2. Transformación y codificación	4
2.3. Visualización y estructura de los datos	4
3. Modelos lineales de referencia	6
3.1. Implementación y comparativa de métricas	6
3.2. Análisis de residuos	6
4. Modelos no lineales de referencia	8
4.1 Remuestreo	8
4.2 Mejor modelo	9
4.3 Conclusiones	10
5. Comparativa de resultados y análisis R^2	10
6. Selección del modelo final y rendimiento	10
7. Autoevaluación y conclusiones finales	11
8. Referencias:	11

1. Descripción del problema

1.1. Descripción del conjunto de datos

Para el desarrollo de esta práctica se ha seleccionado el dataset "Status and Just Gender Pay Gaps", obtenido del repositorio Harvard Dataverse. Este dataset es fruto del proyecto de investigación "Status, fairness, and legitimacy of inequality: Gender and parenthood effects on perceptions of just incomes", financiado por una subvención del National Science Centre de Polonia a Kinga Wysieńska-Di Carlo. El problema se aborda como una tarea de regresión, donde la variable objetivo es just (Salario Justo Percibido), una variable continua que representa la remuneración económica que los encuestados consideran adecuada para diferentes perfiles profesionales.

Se ha elegido este conjunto de datos por su origen real, su dimensionalidad y tipología, ya que contiene una combinación de variables numéricas y categóricas, y por su relevancia social, ya que el problema permite analizar sesgos salariales implícitos, lo que hace que el análisis se pueda interpretar de manera social.

1.2. Descripción de las variables

El dataset original incluye información tanto del encuestado como de los perfiles ficticios (viñetas). Tras la exploración inicial, las variables predictoras clave seleccionadas incluyen características demográficas (v_gender), profesionales (v_occ, v_jobexp) y métricas de prestigio social (v_psko). Se detectó una fuerte asimetría positiva en la variable objetivo just, característica típica de distribuciones económicas, así como la presencia de una variable logarítmica lnjust que fue descartada para evitar data leakage.

2. Preprocesamiento de datos

Siguiendo las directrices que se han visto en clase para asegurar la validez de los resultados, se han realizado las siguientes medidas de limpieza y transformación de los datos:

2.1. Limpieza de los datos y selección de características

Primero se revisó que no hubiera valores perdidos en ninguna variable. A continuación se confirmó que no hubiera valores incoherentes. Los resultados fueron satisfactorios, el rango de edad era de 30 a 65 años y el de experiencia de 1 a 40, lo esperado para un trabajador. Además, se revisó que no existieran casos imposibles o de trabajo infantil, siendo un caso imposible aquel en el que edad - experiencia es menor que 14 años (ver celda 4). Después, se procedió a la selección de características, eliminando por irrelevantes los identificadores `respid` y `vignid`, que no aportan capacidad predictiva, y la variable `Injust` (logaritmo del salario), ya que se trata de una transformación directa de la variable objetivo.

En este punto, con el dataset sin errores, se hizo la partición de los datos (80% para el entrenamiento y 20% para el test). Posteriormente, mediante el análisis de la matriz de correlación en el conjunto de entrenamiento, se detectó una correlación casi perfecta entre la edad (`v_age`) y la experiencia laboral (`v_jobexp`). Se optó por eliminar `v_age` para evitar la multicolinealidad, conservando `v_jobexp` por su mayor relevancia semántica para determinar un salario justo. Asimismo, se eliminó `v_isco3` por su redundancia total con `v_isco`.

El análisis exploratorio reveló la presencia de valores atípicos (outliers) en la variable objetivo `just` (salarios muy elevados). Para evitar data leakage, el cálculo de los umbrales de outliers mediante el Rango Intercuartílico (IQR) se realizó exclusivamente sobre la partición de entrenamiento. Después del análisis, se decidió conservar estos valores atípicos y no eliminarlos, ya que representan casos reales de salarios altos en el mundo real y no errores de medición. Eliminar estos datos simplificaría artificialmente el problema y reduciría la capacidad de generalización del modelo ante salarios altos.


2.2. Transformación y codificación

Para adecuar los datos a los modelos lineales del baseline, se codificaron las variables categóricas mediante `OneHotEncoding`. Dado que las profesiones son nominales y no presentan un orden intrínseco, el uso de `LabelEncoding` habría sido incorrecto, ya que el modelo lineal interpretaría relaciones de magnitud entre las categorías numéricas que no son reales. Además, se escalaron las variables numéricas mediante `StandardScaler` para normalizar las variables numéricas (media 0 y varianza 1). Este paso es importante para evitar que variables con magnitudes grandes tengan los coeficientes de la regresión mucho más elevados que aquellas de menor magnitud.

2.3. Visualización y estructura de los datos



El análisis de Componentes Principales (PCA) revela que, aunque las dos primeras componentes capturan una estructura significativa en los datos (se puede observar en la formación de bloques definidos), no consiguen separar los distintos rangos del target. El

solapamiento de las clases dentro de las agrupaciones indica que la varianza dominante en el conjunto de datos corresponde a características estructurales o demográficas (se puede



observar en el heatmap) y no a diferencias asociadas directamente al objetivo.

Para evaluar si la separabilidad mejoraba en proyecciones no lineales, se aplicó t-SNE con perplejidades variables (25 a 225). Los resultados verifican la complejidad observada en el PCA: hay una superposición importante entre los rangos del target, sin la formación de grupos definidos. La falta de separabilidad (tanto lineal como no lineal) indica que serán necesarios modelos con una gran capacidad para capturar relaciones complejas para obtener buenos resultados.



3. Modelos lineales de referencia

3.1. Implementación y comparativa de métricas


Como punto de partida para evaluar la complejidad del problema y establecer una línea base sólida, se entrenaron y compararon tres enfoques lineales (por su eficiencia computacional y facilidad de interpretación) distintos para verificar si la regularización podía mejorar la capacidad predictiva. Fueron una regresión lineal (enfoque estándar sin penalización), una Ridge (para controlar posible multicolinealidad y sobreajuste mediante la penalización de los coeficientes al cuadrado) y una Lasso (con capacidad para realizar selección de características llevando coeficientes irrelevantes a cero). Los resultados obtenidos en el conjunto de prueba para los tres modelos se pueden observar en la siguiente tabla:

Modelo	R ² (Varianza Explicada)	MAE (Error Medio Absoluto)
Regresión Lineal	0.2379	1134.32 €
Ridge	0.2379	1134.31 €
Lasso	0.2379	1134.26 €

Se observa que el rendimiento es prácticamente idéntico entre las tres variantes. Ridge y Lasso no mejoran al modelo de regresión lineal porque el bajo rendimiento ($R^2 = 0.2379$) no se debe a un problema de overfitting o multicolinealidad, sino a underfitting. El R^2 de 0.2379 indica que, independientemente de la regularización aplicada, el enfoque lineal solo es capaz de explicar el 24% de la variabilidad del salario justo, ya que el modelo es demasiado simple para capturar la relación real entre las variables explicativas y la variable objetivo.

3.2. Análisis de residuos

El análisis de los residuos (realizado sobre el modelo Lasso, aunque es representativo de los tres modelos) demuestra las limitaciones del enfoque lineal:



Se puede observar un patrón claro de heterocedasticidad. Los residuos son pequeños para salarios bajos, pero la varianza del error crece a medida que aumenta el valor predicho. Esto confirma que los modelos lineales pierden precisión al intentar predecir los salarios más altos. Además, la distribución de los errores es asimétrica, lo que indica que incluso con técnicas de regularización, los modelos lineales subestiman los salarios elevados y no se ajustan bien a los sueldos más altos.

4. Modelos no lineales de referencia

Los modelos no lineales escogidos son: **MLP, Random Forest y SVM con RBF**.

4.1 Remuestreo

Para los modelos no lineales, hemos decidido fijar los hiper parámetros de los modelos mediante búsqueda Bayesiana ya que estos modelos ya empiezan a tener un número importante de parámetros y no nos podemos permitir explorar todas las combinaciones de estos.

De hecho, en un principio, decidimos usar el dataset entero para ajustar los hiper parámetros al no estar acostumbrados a conjuntos de datos tan grandes, evidentemente los modelos no se entrenaban en un tiempo razonable así que tuvimos que probar distintas estrategias.

La primera fue reducir considerablemente el número de iteraciones (`n_iter`) de la función de Búsqueda Bayesiana y reducir el tamaño de los conjuntos para la validación cruzada (`cv`). Con esto conseguimos ejecutar los modelos en unos 12 minutos con nuestro mejor ordenador a máximo rendimiento, un tiempo elevado pero razonable. Aún así los resultados son en general peores que los obtenidos con los modelos lineales que se entrenaban en pocos segundos, solamente el modelo de MLP es marginalmente mejor ($r^2: 0.2402 > 0.2379$ y $MAE\ 1130.94\text{€} < 1134.32\text{€}$).

Estos son los resultados completos de este intento:

Modelo: MLP (Redes Neuronales)

Mejor R^2 : 0.2402

MAE: 1130.94 €

Mejores Params: {'activation': 'relu', 'alpha': 0.01, 'hidden_layer_sizes': 300, 'learning_rate': 'invscaling', 'learning_rate_init': 0.001, 'n_iter_no_change': 30}

Modelo: Random Forest

Mejor R^2 : 0.2300

MAE: 1139.44 €

Mejores Params: {'max_depth': 5, 'min_samples_leaf': 1, 'n_estimators': 25}

Modelo: SVM (RBF)

Mejor R^2 : 0.1186

MAE: 1212.52 €

Mejores Params: {'C': 1.513561248436207, 'epsilon': 0.007}

Al no estar muy satisfechos con los resultados, probamos de remuestrear, entrenando a los modelos con una muestra más reducida del dataset completo, en concreto de unos 4000 ejemplares, un número de filas al que estamos más acostumbrados a abordar. Así nos

podríamos permitir aumentar tanto el número de iteraciones de la búsqueda a 15 y también el tamaño de partición para validación cruzada a 4.

Con eso conseguimos entrenar a los modelos en un tiempo algo más reducido y obtenemos unos resultados ligeramente mejores. El modelo que más se ha beneficiado de esto ha sido el SVM (RBF), que de hecho ha conseguido obtener el MAE más bajo de todos.

Estos son los resultados:

Modelo: MLP (Redes Neuronales)

Mejor R^2 : 0.2395

MAE: 1127.32 €

Mejores Params: {'activation': 'relu', 'alpha': 0.01,
'hidden_layer_sizes': 75, 'learning_rate': 'adaptive',
'learning_rate_init': 0.01, 'n_iter_no_change': 40}

Modelo: Random Forest

Mejor R^2 : 0.2318

MAE: 1139.54 €

Mejores Params: {'max_depth': 5, 'min_samples_leaf': 5,
'n_estimators': 10}

Modelo: SVM (RBF)


Mejor R^2 : 0.2224 <- ¡Mucha mejora!

MAE: 1123.44 €

Mejores Params: {'C': 660.6934480075951, 'epsilon': 0.008}

4.2 Mejor modelo

A pesar de la mejora de SVM, hemos concluido que el mejor modelo por su buen R^2 y un MAE, aunque no el mejor, es el segundo mejor por muy poco de todos los modelos que hemos visto hasta ahora.



Respecto a la distribución de los errores de este mejor modelo, no hay nada más que comentar que lo que ya comentamos con los modelos lineales, ya que se mantiene de la misma forma.

4.3 Conclusiones

Podemos llegar a concluir, que a menos de que se tengan los recursos y/o se precise de la máxima precisión posible de los modelos, entrenar modelos no lineales para este problema es exponencialmente más caro que los lineales y a cambio obtenemos muy poco margen de mejora.

5. Comparativa de resultados y análisis R^2

Al comparar los modelos lineales con los no lineales, observamos una ganancia marginal en el rendimiento. Mientras que el modelo base (Lasso) presentaba un R^2 de aproximadamente 0.2379, el mejor modelo no lineal (MLP) apenas alcanza un R^2 de aproximadamente 0.2402.

Pero aquí nos preguntamos una cosa: **¿Por qué un R^2 tan bajo?**

Nosotros también nos hicimos esta pregunta, por lo que hemos estado investigando, la razón técnica de que el R^2 se mantenga en valores cercanos al 0.24 está en la naturaleza del problema.

Según la investigación de Ozili (2022)¹ sobre el modelado empírico en ciencias sociales, un coeficiente de determinación bajo es perfectamente aceptable, ya que el objetivo no es la predicción exacta de una cifra, sino entender la tendencia del comportamiento humano. En este sentido, el comportamiento que el juicio humano está cargado de un ruido o subjetividad intrínseca que actúa como un límite natural para cualquier modelo matemático. Dos personas con el mismo perfil pueden recibir valoraciones de un salario justo muy distintas dependiendo de la ideología o el contexto del encuestado, factores que no están presentes en los datos y que impiden que el modelo explique el 100% de la varianza.

También puede darse el caso, que siendo este tipo de problemas tan complicados, lo que nos haya faltado es recursos y potencia bruta, con más muestreo aún y modelos mucho más refinados, pero todo esto no está a nuestro alcance.

6. Selección del modelo final y rendimiento

Tras el análisis, **hemos seleccionado el MLP (Red Neuronal) como nuestro modelo final**. La decisión se basa en que, aunque el SVM presentó el error absoluto medio (MAE) más bajo en la optimización con remuestreo de un conjunto pequeño de los datos, el MLP demostró una mayor estabilidad y un R^2 superior al ser evaluado con el conjunto de test completo. Este modelo es el que mejor equilibra la capacidad de captar tendencias globales y la precisión puntual.

Estimamos un error de generalización honesto de aproximadamente 1127,32€. Esto significa que nuestro modelo, al predecir el salario a profesionales nunca antes vistos, fallará en promedio esa cantidad respecto a lo que una persona promedio consideraría justo. Es un rendimiento razonable considerando que el rango de salarios en el dataset es muy amplio y que la desviación típica de las respuestas humanas es elevada.

7. Autoevaluación y conclusiones finales

El desarrollo de esta práctica ha sido un éxito en cuanto al aprendizaje. Hemos hecho todo el flujo de trabajo que se suele hacer para resolver problemas del estilo, desde la visualización avanzada con PCA y t-SNE hasta la optimización bayesiana de hiperparámetros.

El primer problema que tuvimos es, que por el hecho de que la mayoría de variables numéricas de este problema son discretas, sin valores intermedios, dándonos un PCA con una figura muy inusual. Al principio incluimos todas las variables, tanto numéricas como categóricas, pero la figura era aún más desconcertante- Al final decidimos construirlo solamente con numéricas pero el resultado no mejoró mucho, seguía siendo un conjunto de tiras- De hecho tuvimos que añadir cierto ruido artificial para que se viese mejor y poder detectar, insatisfactoriamente, si había algún patrón respecto a la variable respuesta.

La mayor dificultad de entre las que hemos ido comentando en el informe, ha sido el coste computacional de los modelos no lineales con 38,000 registros, lo que nos obligó a ser ingeniosos y aplicar técnicas de submuestreo para la búsqueda de parámetros intentado perder el menor rigor estadístico en la evaluación final. Hemos visto de primera mano algo que ya sabíamos, y es que una IA para este tipo de problemas tan complejos **necesita mucha, pero que mucha potencia de cómputo**.

Como conclusión principal, podemos ver que la inteligencia artificial puede modelar conceptos abstractos como lo que es un *salario justo*, pero está limitada por la subjetividad del ser humano y nuestros recursos de estudiante. Como extensión futura, **sería interesante incluir más variables** que definan al máximo posible al encuestado, ya que es probable que el sesgo personal sea la variable oculta que falta para superar el techo del 24% de varianza explicada que hemos visto. Este trabajo nos ha permitido entender que en *Machine Learning* no siempre el modelo más complejo es el mejor, y que la interpretación del error es tan importante como el error mismo.